

2026 年人工智能导论大作业

（可解释的谣言检测）

任务名称： 可解释的谣言检测

完成组号： 10

小组人员： 迪力夏提·艾呢瓦尔 524020910240

完成时间： 2026 年 6 月 20 日

一、 问题描述和任务目标

谣言检测是社交媒体信息治理中的关键任务。本作业要求构建一个可解释的谣言检测模型，该模型不仅需要对推文进行二分类（0 表示非谣言，1 表示谣言），还需输出文字形式的判断依据，说明分类的推理过程。数据集包含 2,840 条训练样本和 401 条验证样本，涵盖 7 个不同事件类别。模型需兼顾分类准确率、可解释性、泛化能力以及合理的运行时间。

二、 模型设计

（1）整体架构

本系统采用深度学习 + 多策略解释的复合架构。分类模块使用预训练语言模型 DistilBERT 进行微调，输出二分类标签与置信度；解释模块结合梯度归因、语言学模式分析与模板化自然语言生成，将模型内部决策信号转换为人类可读的判断依据。整体流程为：输入文本 → 文本清洗 → DistilBERT 编码与分类 → 梯度归因分析 → 语言学特征检测 → 解释文本合成 → 输出。

（2）分类模型设计

分类模块基于 distilbert-base-uncased 构建。DistilBERT 是 BERT 的知识蒸馏版本，保留了 97% 的性能，参数量减少 40%，推理速度提升 60%，适合在 CPU 环境下运行。在预训练模型之上添加一个二分类线性头，使用交叉熵损失进行端到端微调。主要超参数设置：最大序列长度 128，批大小 16，学习率 $5e-5$ ，优化器 AdamW，训练轮数 10，采用线性预热调度策略（预热比例 0.1）。训练过程中在验证集上评估准确率，保留最佳模型以防过拟合。

（3）解释模块设计（可解释性）

解释模块采用三种互补策略生成判断依据：

① 梯度归因分析：对预测类别的 logit 反向传播计算词嵌入梯度，以梯度范数衡量各 token 对决策的贡献度，识别出模型重点关注的关键词语。

②

语言学模式检测：基于正则表达式匹配谣言和非谣言的语言特征。谣言特征包括：突发新闻用语（BREAKING）、未经验证的说法（allegedly）、情绪化表达（shocking）、隐瞒指控（cover-up）、号召性用语（wake up）等；非谣言特征包括：明确信源引用（according to）、官方确认用语（confirmed）、研究数据引用等。

③

模板化自然语言生成：将归因结果和语言学分析发现组织成连贯的解释段落，包含预测结果、置信度、关键信号词和推理逻辑。

三、 实验结果

（1）实验设置

实验环境：Python 3.13, PyTorch 2.12（CPU），transformers 4.x。训练集 2,840 条（非谣言 1,600 条，谣言 1,240 条），验证集 401 条。评估指标包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）和 F1 值。

（2）模型性能与分析

验证集评估结果如下表所示：

类别	精确率	召回率	F1 值	样本数
非谣言	0.86	0.89	0.88	226
谣言	0.85	0.82	0.83	175
加权平均	0.86	0.86	0.86	401

整体准确率为 85.79%（344/401）。混淆矩阵显示：非谣言误判为谣言 25 例，谣言误判为非谣言 32 例。

分析：(1) 模型在两类上表现均衡，非谣言类的召回率略高（0.89），说明模型识别非谣言较为保守；(2) 谣言类的 F1 值达 0.83，表明模型能有效捕捉谣言的语言模式；(3) 模型在 CPU 环境下单条推理时间不足 1 秒，满足实时性要求；(4) 解释模块能准确识别文本中的关键信号词和语言模式，生成的判断依据具有较好的可读性和说服力。

四、 工作总结

本项目成功实现了一个可解释的谣言检测系统。系统采用 DistilBERT作为分类骨干，结合梯度归因、语言学模式分析和模板生成三种策略，同时给出分类结果和判断依据。在验证集上取得 85.79% 的准确率和 0.86 的加权 F1 值，推理速度满足实用需求。模型对 7个不同事件类别的推文具有良好的泛化能力。

不足之处：

- (1) 语言学模式依赖人工规则，覆盖范围有限；
- (2) 缺少解释质量的自动化评估指标；
- (3) 未利用用户画像、传播网络等多模态信息。

未来可尝试引入更大规模的语言模型（如 LLaMA、ChatGPT等）来提升解释的自然度和丰富度，同时可利用注意力可视化增强可解释性的直观性。