

2026 《人工智能导论》大作业

(可解释的谣言检测)

|      |                        |
|------|------------------------|
| 任务名称 | 可解释的谣言检测               |
| 完成组号 | 10                     |
| 小组人员 | 迪力夏提·艾呢瓦尔 524020910240 |
| 完成时间 | 2026 年 6 月 20 日        |

1. 任务目标

构建可解释的谣言检测模型，对推文进行二分类（0=非谣言，1=谣言），同时输出自然语言判断依据，说明分类推理过程。数据集含 2,840 条训练样本和 401 条验证样本，涵盖 7 个事件类别。模型需兼顾准确率、可解释性、泛化能力及运行时间。

2. 具体内容

(1) 实施方案

本系统采用“深度学习+多策略解释”复合架构。分类模块基于 DistilBERT（distilbert-base-uncased）微调，添加二分类线性头，交叉熵损失端到端训练。DistilBERT 是 BERT 的知识蒸馏版本，保留 97%性能，参数量减 40%，推理速度提升 60%。超参数：max\_len=128, batch=16, lr=5e-5, AdamW 优化器，训练 10 轮，线性预热比例 0.1。

处理流程：原始文本 → 文本清洗（去 URL/特殊字符）→ DistilBERT 编码分类 → 梯度归因 → 语言学特征检测 → 解释文本合成 → 输出。

小组分工协作情况:

|           |      |        |
|-----------|------|--------|
| 小组成员      | 贡献度  | 分工     |
| 迪力夏提·艾呢瓦尔 | 100% | 完成全部内容 |
| 李飞翰       | 0%   | 无      |

|     |    |   |
|-----|----|---|
| 叶培堃 | 0% | 无 |
|-----|----|---|

（2）核心代码分析

- ① DistilBERT 分类器：加载 HuggingFace 预训练权重，替换分类头为 nn.Linear(768, 2)，前向传播输出 logits，经 softmax 得类别与置信度。使用 transformers.Trainer API 封装训练。
- ② 梯度归因模块：对预测类别对应的 logit 进行反向传播，获取词嵌入层的梯度，以梯度 L2 范数衡量各 token 对决策的贡献度，提取 top-k 关键 token 作为模型关注的信号词。
- ③ 语言学模式检测：基于正则表达式匹配谣言特征词（BREAKING、allegedly、shocking、cover-up 等）与非谣言特征词（according to、confirmed、official 等），涵盖突发新闻用语、未验证说法、情绪化表达、信源引用等语言维度。
- ④ 解释生成：将梯度归因识别的关键 token 和语言学检测发现的特征，通过模板化方式组织为连贯的自然语言解释段落，包含预测结果、置信度、关键信号词及推理逻辑。

（3）检测结果分析（正确率等）

实验环境：Python 3.13 + PyTorch 2.12（CPU）+ transformers 4.x。验证集 401 条（非谣言 226/谣言 175），评估指标为准确率、精确率、召回率、F1 值。整体准确率 85.79%（344/401），非谣言误判 25 例，谣言误判 32 例。

| 类别   | 精确率  | 召回率  | F1 值 | 样本数 |
|------|------|------|------|-----|
| 非谣言  | 0.86 | 0.89 | 0.88 | 226 |
| 谣言   | 0.85 | 0.82 | 0.83 | 175 |
| 加权平均 | 0.86 | 0.86 | 0.86 | 401 |

分析：模型在两类上表现均衡；非谣言类召回率略高（0.89），说明模型识别非谣言较为保守；谣言类 F1 值达 0.83，表明模型能有效捕捉谣言的语言模式；CPU 环境下单条推理时间不足 1 秒，满足实时性要求。

（4）判断依据的分析（可解释性等）

解释模块采用三种互补策略确保判断依据的可信度与可读性：

① 梯度归因：对预测类别的 logit 反向传播，以词嵌入梯度范数衡量各 token 对决策的贡献度，识别模型重点关注的信号词，使黑盒决策过程透明化。

② 语言学模式检测：基于正则匹配谣言与非谣言的语言特征——谣言倾向使用突发新闻用语（BREAKING）、未验证指控（allegedly）、情绪化表达（shocking）等；非谣言则包含明确信源（according to）、官方确认（confirmed）等特征。

③ 模板化自然语言生成：将归因与语言学发现综合组织为连贯的解释段落，包含预测结果、置信度、关键信号词和推理逻辑，确保可读性和说服力。

### 3. 工作总结

#### （1）收获与心得

通过本项目掌握了预训练语言模型（DistilBERT）的微调方法，深入理解了梯度归因、语言学模式检测等可解释性 AI 技术。验证准确率 85.79%，加权 F1 值 0.86，体会到深度学习与符号化规则结合的有效性，认识到可解释性在 AI 应用中的重要价值。

#### （2）遇到问题及解决思路

主要问题：①语言学模式依赖人工规则，覆盖范围有限，对新型谣言表述的适应力不足——可通过引入大语言模型（如 LLaMA）自动发现语言模式来改进；②缺乏解释质量的自动化评估指标——可设计人工评估标准或基于参考解释的自动评分机制；③未利用用户画像、传播网络等多模态信息——后续可融合更多特征维度提升检测效果。

### 4. 课程建议

建议适当增加深度学习可解释性的实验课，让学生通过实践深入理解模型可解释性方法；同时可引入大语言模型在 NLP 任务中的应用案例，帮助学生了解前沿技术发展趋势。